

封兆欣 (Zhaoxin Feng)

语言科学与技术学系
香港理工大学
中国香港特别行政区

zhaoxinbetty.feng@connect.polyu.hk
<https://zhaoxin-feng.github.io/>

教育背景

[†] 表示预计

- 2024–2028[†] 博士, 香港理工大学
导师: Emmanuele Chersoni; 副导师: 黄居仁 (Huang Chu-Ren)
- 2027–2028[†] 访问博士生, 加州大学圣地亚哥分校 (导师: Julian McAuley)
- 2023 春 交换生, 香港理工大学
- 2020–2024 理学学士, 教育技术学 (辅修: 数据科学), 北京师范大学
GPA: 3.7/4.0 (前 7%); 优秀本科毕业生

研究概述

我的研究围绕一个核心问题: 当大语言模型 (LLM) 以及基于 LLM 的智能体与人交互时, 我们能否信赖它们? 我从两个层面展开: 模型内部如何表征意义, 以及它们在与人类交互时如何表现。

- **内部表征 (可靠性与可解释性)**。我探究 LLM 如何表征人类语言: 在自回归 LLM 中启用双向注意力是否会重塑其词汇语义表征, 以及其词嵌入与人类心理词库判断之间的异同。核心问题在于, 模型对意义的内部把握是否足够可靠、值得信赖。
- **交互中的行为可靠性**。我研究 LLM 及智能体在与用户交互时的行为表现: 从思维链推理既能缓解、又会掩盖的谄媚 (sycophancy) 现象, 到模型在中文语音歧义上的推理失败, 再到能够记住用户偏好、却无法据此行动的记性型智能体。

长远而言, 我希望在**个性化 (personalization)** 方向做出贡献: 构建一个通过与用户持续交互而不断加深记忆的长期个人智能体——它真正理解你所处的情境, 并在此过程中始终保持可靠。我的博士论文《*Rethinking Memory for Long-Term LLM Agents: Not Just Remembering, But Acting*》以智能体记忆为切入点迈出第一步: 显式与隐式偏好如何从日常交互中被抽取; 记忆如何被检索、更新与遗忘; 以及如何评估智能体不仅存储了什么, 更能否可靠地据此行动。

论文发表

^{*} 表示共同第一作者

审稿中的投稿

- [1] Ma, J., **Feng, Z.**, Chersoni, E., & Chen, S. Every time I hire a linguist, inference costs go down: On linguistic rules as effective prompt compressors. 投稿至 *ACL Rolling Review* (投稿 EMNLP 2026)。

- [2] **Feng, Z.**, Ma, J., & Chersoni, E. Know it, act on it: Investigating memory utilization in LLM personalization. 投稿至 *ACL Rolling Review* (投稿 EMNLP 2026)。

会议论文

- [1] Chen, Z., **Feng, Z.**, Yip, T. P., Ma, J., Chersoni, E., & Li, B. (2026). PCA-guided activation scaling for monotonic bidirectional control over LLM sycophancy. In *Proceedings of the Conference on Language Modeling (COLM 2026)*。
- [2] **Feng, Z.**, Chen, Z., Ma, J., Yip, T. P., Chersoni, E., & Li, B. (2026). Good arguments against the people pleasers: How reasoning mitigates (yet masks) LLM sycophancy. In *Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (ACL 2026)*。
- [3] Ma, J.^{*}, **Feng, Z.**^{*}, Chersoni, E., Song, H., & Zhang, Z. (2025). PhonoThink: Improving large language models' reasoning on Chinese phonological ambiguities. In *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing (EMNLP 2025, 口头报告)*。
- [4] **Feng, Z.**, Ma, J., Chersoni, E., Zhao, X., & Bao, X. (2025). Learning to look at the other side: A semantic probing study of word embeddings in LLMs with enabled bidirectional attention. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (ACL 2025, 口头报告)*。
- [5] Song, H., **Feng, Z.**, Chersoni, E., & Huang, C.-R. (2025). Which model mimics human mental lexicon better? A comparative study of word embedding and generative models. In *Proceedings of the 16th International Conference on Computational Semantics (IWCS 2025, 口头报告)*。
- [6] Ma, J.^{*}, **Feng, Z.**^{*}, Song, H., Chersoni, E., & Chen, Z. (2025). Reasoning or memorization? Investigating LLMs' capability in restoring Chinese internet homophones. In *Proceedings of the 3rd Workshop on Towards Knowledgeable Language Models (KnowFM 2025)*。
- [7] Chen, Z., **Feng, Z.**, Ma, J., Xu, J., & Li, B. (2025). Can LLMs recognize their own analogical hallucinations? In *Proceedings of the 3rd Workshop on Towards Knowledgeable Language Models (KnowFM 2025)*。

主要课程

- | | |
|-----------|--|
| 2024–至今 | 博士阶段: 计算语言学; 高级自然语言处理; 计算机算法高级专题; 面向基础模型的大规模机器学习系统; 人工智能 |
| 2020–2024 | 本科阶段: 单变量微积分; 多元微积分与线性代数; 离散数学; 概率论与数理统计; 随机过程; 深度学习; 数学建模; 计算机网络编程; 数据结构; 模式识别导论; 软件工程; 人工智能教育应用 |

主要荣誉与奖项

- 2026 香港理工大学博士生国际合作研究奖学金 (ICRF)
- 2025 香港特别行政区人才发展奖学金 (HKSAR Talent Development Scholarship)
- 2024 北京师范大学优秀本科毕业生
- 2024 美国大学生跨学科建模竞赛 (ICM) 荣誉提名奖
- 2023 香港理工大学校长博士奖学金 (PolyU Presidential PhD Fellowship)
- 2022 北京师范大学一等学业奖学金
- 2022 北京师范大学一等竞赛奖学金
- 2022 北京师范大学优秀毕业生
- 2022 第十五届全国大学生数学竞赛二等奖
- 2022 国际基因工程机器大赛 (iGEM) 金奖
- 2022 志愿服务奖

教学经历

- 2026 春 助教,《语言研究中的编程与数据分析》
- 2025 秋 助教,《语言与传播中的计算机编程》
- 2025 春 助教,《语言研究中的编程与数据分析》

科研与实习经历

- [1] 字节跳动, 中国北京 2024 年 2 月 – 2024 年 6 月
策略产品经理实习生 (AI 应用方向), ZERO 团队。面向教育场景, 为豆包在 OCR、检索增强生成 (RAG)、插件及智能体 workflow 等方向制定产品策略。
- [2] 蒙特利尔综合理工学院, 加拿大蒙特利尔 2023 年 5 月 – 2023 年 8 月
科研实习生。主导项目 *Understanding the Characteristics of Internet Slangs in OSI Discussions*; 并参与另一项人机交互相关研究, 负责将实体物件整合进 AR 交互, 并在 Unity 中开发虚拟按钮功能。
- [3] 中国科学院心理研究所, 中国北京 2022 年 10 月 – 2023 年 1 月
科研实习生。使用 Python 与 R 对超过 50,000 行的数据集完成数据分析与文本挖掘。